


편의점 최적입지 스코어링 및 현장 검증

서울 공공데이터 기반 · 중랑구 100m 격자 분석 · 개인 프로젝트

서울 전체 상권의 편의점 매출 데이터로 '좋은 입지의 조건'을 학습해, 중랑구를 100m 격자로 나눠 출점 후보지에 점수를 매겼습니다. 도로·하천·산지처럼 물리적으로 출점이 불가능한 곳을 걸러 539개 후보지를 도출한 뒤, 상위 후보 5곳을 직접 답사해 모델이 맞힌 것과 놓친 것을 규명했습니다. 핵심은 점수를 내는 데서 그치지 않고, 그 점수가 현장에서 성립하는지까지 확인했다는 점입니다.

프로젝트 결과

중랑구 편의점 입지 스코어링 — 최종 결과



중랑구 1,858개 격자 스코어링 결과. 빨강=신규 후보지(고득점·무점포), 초록=검증된 자리(고득점·기존점포), 갈색=출점불가(건물·상가 없음).

539개

물리적 출점 가능 지역 중
도출한 신규 후보지

25.8%

도로·하천·산지 등
출점불가 지역 마스킹

46.4%

실제 매출 상위권 적중률
(무작위 대비 2.3배)

5곳

상위 후보지
직접 현장 답사

무엇을, 왜

입지 분석·선정에서는 늘 '어떤 요인에 얼마의 가중치를 줄 것인가'를 정하는 일이 중요한 과제입니다. 이 프로젝트는 그 과제를 가중치를 데이터로 직접 학습하는 방식으로 풀어보고자 시작했습니다. 사람이 임의로 정한 가중치 대신, 서울 전체 편의점 매출이 실제로 어떤 입지 요인과 함께 움직이는지를 머신러닝으로 학습시켰습니다.

다만 목표는 '매출 금액을 정확히 맞추는 예측'이 아니라, '어느 자리가 상대적으로 더 유망한가'를 줄 세우는 스코어링입니다. 그래서 평가지표도 절대 오차가 아니라 순위 일치도를 중심에 두었습니다.

어떻게 했나



- 데이터: 서울열린데이터광장·소상공인시장진흥공단·국가데이터처의 공공데이터 9종과, 유동인구 결합의 정확도를 위해 SGIS(통계지리정보서비스)의 승인 집계구 경계를 추가로 확보해 사용.
- 12개 입지 피쳐: 경쟁 밀도(반경별 편의점 수), 대중교통 접근성(지하철 거리·승하차량, 버스정류장), 생활인구(주간/야간 × 평일/주말), 집객시설(음식점·학원 수).
- 출점불가 마스크: 건물과 상가가 모두 없는 격자(도로·하천·산지·공원)를 걸러, 점수가 높아도 실제로는 출점이 불가능한 곳을 후보에서 제외.

모델 성능 — 숫자의 의미

46.4% Top20% 적중률 실제 매출 상위 20% 상권 중 46.4%를 모델도 상위권으로 지목. 무작위(20%)보다 2.3배 정확.	0.312 순위 일치도(스피어만) 실제 매출 순위와 예측 순위의 일치 정도(0=무작위, 1=완벽). 위치 정보만으로 '상대적 우열'을 유의미하게 구분.	전용화 순위 스코어링 용도 학습 $R^2(0.54)$ 과 테스트 $R^2(0.02)$ 격차가 커, 절대 금액 예측 대신 순위 매기기 전용으로 용도를 못박음.
---	--	---

현장 검증: 모델을 직접 걸어서 확인하다

상위 후보 10곳 중 5곳을 직접 답사해, 모델의 판단과 현장을 대조했습니다.

순위	장소	판정	현장에서 확인한 근거
1위	상봉역	적중	지하철 개찰구 밖 무점포 확인, 낮·저녁 이중 유동인구
3위	타임호프	조건부 적중	고령층 근린 상권, 무인마트의 취급 공백이 오히려 기회
8위	먹자골목	진입 불가	수요는 확실하나 빈 점포 없음(위반건축물 5건이 방증)
2위	금강사거리	위양성	초등학교발 생활인구 착시, 현장 유동 거의 없음
9위	진로아파트	위양성	격자가 순수 아파트 단지 내부 → 물리적 설치 불가



1위 상봉역 — 적중. 초역세권이지만 개찰구 밖에 편의점이 없어 유동인구가 미포섭 상태였음.



9위 진로아파트 — 위양성. 고독점 격자가 아파트 단지 내부였고, 실제로는 출점이 불가능했음.

핵심 통찰 — 한계를 현장으로 규명하다

5곳 중 완전 적중은 1곳이었지만, 이 결과가 오히려 프로젝트의 핵심입니다. 모델은 '상권 매출'로 학습됐기에 사실상 '편의점이 이미 몰린 곳(상업 밀집도)'을 학습했습니다. 그래서 활발한 상권은 잘 찾아내지만, 비어 있는 자리가 진짜 기회인지 — 아니면 순수 주거단지(9위)나 초등학교 탓에 유동인구가 부풀려진 착시(2위)인지는 구분하지 못합니다. 이 한계는 데이터만 보서는 드러나지 않았고, 직접 걸어봤기에 규명할 수 있었습니다. 모델을 신뢰하되 맹신하지 않고, 정량 분석과 현장 검증을 함께 쓰는 것이 이 프로젝트의 결론이자 태도입니다.

나의 역할과 프로젝트의 성장

파이프라인 코드 작성에는 AI 코딩 도구(Claude Code)를 활용했습니다. 대신 데이터 선정, 피쳐 설계, 좌표계·마스킹 규칙 같은 방법론적 판단, 모델 버전 비교와 원인 진단, 답사 대상 선정과 현장 검증, 결과 해석은 모두 직접 수행했습니다.

프로젝트는 매 단계의 판단으로 나아졌습니다. 유동인구와 집계구 경계가 0% 일치하던 문제를 코드 체계 차이가 아니라 '기준 연도 불일치'로 재진단해 알맞은 경계를 확보하고 100% 일치를 만들었고, 성능이 떨어진 모델 버전의 원인을 타깃 변경과 피쳐 추가로 분리 실험해 진짜 원인을 짚었으며, 지도에서 산지에 후보지가 몰린 것을 눈으로 발견해 마스킹 규칙을 고쳐 오탐을 걸러냈습니다. AI가 준 결과를 그대로 받지 않고 '왜 그런지 되묻고 검증하는 것'이 제 역할이었습니다.

전체 코드 · 데이터 명세 · 상세 검증 기록 → github.com/KHWGISPort/gis-portfolio